

1

List 4:

1) Forma Matricial do sistema estrutural:

$$Y\Gamma + X\beta = \bar{E}$$

$N \times M \quad M \times M \quad N \times K \quad K \times M \quad N \times M$

$$(Y_1 \ Y_2 \ Y_3) \begin{bmatrix} 1 & 0 & \beta_{31} \\ \beta_{12} & 1 & 0 \\ \beta_{13} & \beta_{23} & 1 \end{bmatrix} + (X_1 \ X_2 \ X_3) \begin{bmatrix} \beta_{11} & 0 & 0 \\ 0 & \beta_{22} & \beta_{32} \\ \beta_{12} & \beta_{23} & 0 \end{bmatrix} = (\varepsilon_1 \ \varepsilon_2 \ \varepsilon_3)$$

Hipóteses

$$\begin{cases} |\Gamma'| \neq 0 \\ \text{rank}(x) = 3 \\ E(\varepsilon | x) = 0 \\ E(\varepsilon \varepsilon' | x) \text{ positiva - definida} \end{cases}$$

$$M = 3 \Rightarrow M-1 = 2$$

- condições de ordem:
- Eg (1): 1 restrição de exclusão; 3 endógenas  $\Rightarrow 3-1=2 \Rightarrow$  exatamente sub-identificada
  - Eg (2): 2 restrições de exclusão; 2 endógenas  $\Rightarrow$  exatamente identificada
  - Eg (3): 2 restrições de exclusão; 2 exógenas  $\Rightarrow$  sobre-identificada



Condições de posto:  $\Delta = \begin{bmatrix} I \\ B \end{bmatrix} = \begin{bmatrix} 1 & 0 & p_{31} \\ p_{12} & 1 & 0 \\ p_{13} & p_{23} & 1 \\ \beta_{11} & 0 & 0 \\ 0 & \beta_{22} & \beta_{12} \\ \beta_{13} & \beta_{23} & 0 \end{bmatrix}$

$$R = \begin{bmatrix} 0 & 0 & 0 & 0 & 1 & 0 \\ 1 & 0 & 0 & 1 & 0 & 0 \\ 0 & 1 & 0 & 1 & 0 & 1 \end{bmatrix}$$

$$R_2 \Delta = \begin{bmatrix} 0 & 0 & 0 & 0 & 1 & 0 \\ 0 & 1 & 0 & 1 & 0 & 1 \end{bmatrix} \begin{bmatrix} 1 & 0 & p_{31} \\ p_{12} & 1 & 0 \\ p_{13} & p_{23} & 1 \\ \beta_{11} & 0 & 0 \\ 0 & \beta_{22} & \beta_{12} \\ \beta_{13} & \beta_{23} & 0 \end{bmatrix} = \begin{bmatrix} 0 & \beta_{22} & \beta_{12} \\ (\beta_{12} + \beta_{11} + \beta_{13})(1 + \beta_{23}) & 0 & 0 \end{bmatrix}$$

Posto( $R_2 \Delta$ ) = 2

$\Rightarrow$  Eq (2) é exatamente identificada.

$$R_3 \Delta = \begin{bmatrix} 0 & 0 & 0 & 0 & 1 & 0 \\ 1 & 0 & 0 & 1 & 0 & 0 \end{bmatrix} \begin{bmatrix} 1 & 0 & p_{31} \\ p_{12} & 1 & 0 \\ p_{13} & p_{23} & 1 \\ \beta_{11} & 0 & 0 \\ 0 & \beta_{22} & \beta_{12} \\ \beta_{13} & \beta_{23} & 0 \end{bmatrix} = \begin{bmatrix} 0 & \beta_{22} & \beta_{12} \\ 1 + \beta_{11} & 0 & p_{31} \end{bmatrix}$$

posto( $R_3 \Delta$ ) = 2  $\Rightarrow$  sobre-identificada

2) a) Eq (1) apenas (visto em sala)

b)  $E(\varepsilon_2 | \varepsilon_1) = 0 \Rightarrow \text{cov}(\varepsilon_2, \varepsilon_1) = 0$

~~Eq (2)~~ Forma reduzida:  $y_1 = a_0 + a_1 x_1 + u_1$ ;  $a_0 = 0$

$$y_2 = b_0 + b_1 x_1 + u_2 \quad ; \quad b_0 = 0$$

$$a_1 = \frac{p_{12} \beta_{21}}{1 - p_{21} p_{12}}$$

$$b_1 = \frac{\beta_{21}}{1 - \beta_{21} p_{12}}$$

$$u_1 = \frac{\varepsilon_1 + p_{12} \varepsilon_2}{1 - p_{12} p_{21}}$$

$$u_2 = \frac{\varepsilon_2 + p_{21} \varepsilon_1}{1 - p_{12} p_{21}}$$

$$\hat{p}_{12} = \frac{q_1}{b_1}$$

$$② S_{v_1}^2 = \frac{1}{\mu_1} \sum v_{1i}^2 \approx \sigma_{v_1}^2 \quad ; \quad S_{v_2}^2 \approx \sigma_{v_2}^2$$

$$\hat{\sigma}_{v_1}^2 = \frac{\sigma_1^2 + p_{12}^2 \hat{\sigma}_2^2}{(1 - p_{12} p_{21})^2} \quad \hat{\sigma}_{v_2}^2 = \frac{\sigma_2^2 + p_{21}^2 \hat{\sigma}_1^2}{(1 - p_{12} p_{21})^2}$$

$$\hat{\sigma}_{v_1 v_2} = \text{cov}(v_1, v_2) = \frac{1}{(1 - p_{12} p_{21})^2} (p_{21} \hat{\sigma}_1^2 + p_{12} \hat{\sigma}_2^2)$$

⇒ Resolver sistema

$$\begin{cases} \hat{\sigma}_{v_1}^2 = \frac{\sigma_1^2 + p_{12}^2 \hat{\sigma}_2^2}{(1 - p_{12} p_{21})^2} \\ \hat{\sigma}_{v_2}^2 = \frac{\sigma_2^2 + p_{21}^2 \hat{\sigma}_1^2}{(1 - p_{12} p_{21})^2} \\ \hat{\sigma}_{v_1 v_2} = \frac{p_{21} \hat{\sigma}_1^2 + p_{12} \hat{\sigma}_2^2}{(1 - p_{12} p_{21})^2} \end{cases}$$

p/  $\hat{\sigma}_1^2, \hat{\sigma}_2^2$  e  $\hat{p}_{12}$

$$\Rightarrow \text{Resolver } \hat{p}_{12} = (1 - \hat{p}_{12} \hat{p}_{21}) \hat{\sigma}_1$$

3) a) Ambas as equações são identificáveis

eq 1: ordem → 1 exclusão, 2 em dígitos ( $2-1=1$ )

posto:  $(0 \ 0 \ 0 \ 1 \ 0) \begin{pmatrix} 1 & -1 \\ \alpha_1 & \beta_1 \\ \alpha_2 & 0 \\ 0 & \beta_2 \\ \alpha_0 & \beta_0 \end{pmatrix} = (0 \ \beta_2) \rightarrow \text{posto} = 1 = M-1$

eq 2: análogo

ordem → 1 exclusão p/ 2 em dígitos

$$\text{posto: } R\Delta = (\alpha_2 \ 0)$$

b) Se  $\alpha_2 = 0$  a condição de posto da eq 2 fica  $R\Delta = (0 \ 0)$   
e/ posto = 0 (sub-identificável)



$$\text{Na forma matemática } p = \tilde{u}_{00} + \tilde{u}_{01}y + \tilde{u}_{12}w + \varepsilon_p$$

$$\tilde{u}_{00} = \frac{\beta_0 - \alpha_0}{\alpha_1 - \beta_1}, \quad \tilde{u}_{01} = \frac{\beta_2}{\alpha_1 - \beta_1}, \quad \tilde{u}_{12} = -\frac{\alpha_2}{\alpha_1 - \beta_1}$$

$$q = \tilde{u}_{00} + \tilde{u}_{01}y + \tilde{u}_{02}w + \varepsilon_q$$

$$\tilde{u}_{00} = \frac{\alpha_0\beta_2 - \alpha_1\beta_0}{\beta_1 - \alpha_2}, \quad \tilde{u}_{01} = -\frac{\alpha_1\beta_2}{\beta_1 - \alpha_2}, \quad \tilde{u}_{02} = \frac{\alpha_2\beta_1}{\beta_1 - \alpha_2}$$

$$\text{Se } \alpha_2 = 0 \Rightarrow \tilde{u}_{02} = \tilde{u}_{12} = 0$$

$$p / \theta = \begin{bmatrix} \tilde{u}_{00} & \tilde{u}_{10} \\ \tilde{u}_{01} & \tilde{u}_{11} \\ \tilde{u}_{02} & \tilde{u}_{12} \end{bmatrix} \Rightarrow M_0 : R\theta = r \text{ onde } R = (0 \ 0 \ 1) \\ r = (0 \ 0)$$

$$\text{Teste de Wild: } (R\hat{\beta} - r)' [v_{an}(R\hat{\beta})]^{-1} (R\hat{\beta} - r) \sim \chi^2_{(2)}$$

$$W = (\tilde{u}_{02} \ \tilde{u}_{12})' \left[ \begin{array}{cc} \hat{\sigma}_{02}^2 & \hat{\sigma}_{0212} \\ \hat{\sigma}_{0212} & \hat{\sigma}_{12} \end{array} \right]^{-1} (\tilde{u}_{02} \ \tilde{u}_{12}) \sim \chi^2_{(2)}$$

c) Obs: este é um teste assintótico. Em amostras grandes pode-se reverter o teste F

c) A identificação está na restrição de excluir (*Greene*) não no sinal de  $\alpha_2$ . Se a hipótese teórica de que  $y$  é bom instrumento para  $p$  na eq 1 estiver errada, de modo adianto o sinal de  $\alpha_2$  ser positivo. Além disso, se  $y$  for instrumento fraco para  $p$  e a amostra for pequena é possível que o sinal de  $\hat{\alpha}_2$  seja inclusive negativo por essa amostral.

3)

4) a)  $\frac{\partial E(\cdot)}{\partial x_1} = \beta_1 + \beta_3 x_2 \Rightarrow \mathbb{E}\left(\frac{\partial E(\cdot)}{\partial x_1}\right) = \beta_1 + \beta_3 \mu_2$

$$\frac{\partial E(\cdot)}{\partial x_2} = \beta_2 + \beta_3 x_1 + 2\beta_4 x_2 \Rightarrow \mathbb{E}\left(\frac{\partial E(\cdot)}{\partial x_2}\right) = \beta_2 + \beta_3 \mu_1 + 2\beta_4 \mu_2$$

b)  $E[\ln(x_1, x_2)] = \beta_0 + (\alpha_1 - \beta_3 \mu_2)x_1 + (\alpha_2 - \beta_3 \mu_1 - 2\beta_4 \mu_2)x_2$   
 $+ \beta_3 x_1 x_2 + \beta_4 x_2^2$   
 $= \beta_0 + \alpha_1 x_1 + \alpha_2 x_2 + \beta_3 [-\mu_2 x_1 - \mu_1 x_2 + x_1 x_2] +$   
 $\beta_4 [x_2^2 - 2\mu_2 x_2]$

c) (i) conhecendo os  $\mu$ 's, você pode construir novas variáveis

$$z_1 = -\mu_2 x_1 - \mu_1 x_2 + x_1 x_2$$

$$z_2 = x_2^2 - 2\mu_2 x_2$$

(ii) regressar  $y = \beta_0 + \alpha_1 x_1 + \alpha_2 x_2 + \beta_3 z_1 + \beta_4 z_2 + \epsilon$

Caso não conheça os  $\mu$ 's não posso fazer o passo (ii)

5) c) Na lista anterior (e em sala), vimos que  $\hat{\beta}_2$  pode ser obtido por MCO através (i) de um primeiro regressão regressão  $y_1$  vs  $\hat{\beta}_1$  e  $y_2$  vs  $\hat{\beta}_1$ , e posteriormente (ii) regressão do resíduo da primeira regressão contra o resíduo da segunda.

Da lista passada (exercício 3b), temos que

$$\hat{b}_2 = (\mathbf{Y}_2' M_2 \mathbf{Y}_2)^{-1} \mathbf{Y}_2' M_2 \mathbf{y}_1 ; \text{ onde } M_2 = I - P_2 \text{ projeto}$$

no espaço de  $\hat{\mathbf{z}}$

O espaço de  $\hat{\mathbf{z}}$  tem como propriedade ser exatamente ortogonal a  $\mathbf{z}$ , de modo que  $M_2 = P_{\mathbf{z}}$

$$\Rightarrow \hat{b}_2 = (\mathbf{Y}_2' P_{\mathbf{z}} \mathbf{Y}_2)^{-1} \mathbf{Y}_2' P_{\mathbf{z}} \mathbf{y}_1 = \hat{b}_2^{\mathbf{V}_{\mathbb{D}}}$$

4) b) Como  $y_2 \not\perp \varepsilon$ , os parâmetros estimados são inconsistentes e inconsistentes, de modo que as previsões para o teste não são válidas e portanto o teste também não. Para que pudéssemos fazer tal teste, seria necessário  ~~$y_2 \perp \varepsilon$~~   $y_2 \perp \varepsilon$ , mas nesse caso não precisaríamos de VI.

Caso  $\text{cov}(z, y_2) = 0$ , a medida que não é  $y_2$  no regressão mantém  $b_1$  constante, e o teste  $S_1 = 0$  seria então pl  $\text{cov}(z, \varepsilon) = 0$  (exercício 2 da lista anterior).

Como não sabemos a priori se  $\text{cov}(\varepsilon, y_2) = 0$  (aliás, caso em que  $\varepsilon$  não seria bom instrumento), o

teste é inválido.

$$y_i = b_0 + b_1 z + b_2 y_2^* + u + v$$

$$e = \cancel{y_2} - y_2^*$$

$$\text{posto} \cancel{\text{verdade}}: y_i = b_0 + b_1 z + b_2 (y_2 - \varepsilon) + \frac{q - a_0 - w}{a_1} + v$$

$$= \left( b_0 - \frac{a_0}{a_1} \right) + b_1 z + b_2 y_2 + \frac{1}{a_1} q + \underbrace{\left[ v - \frac{w}{a_1} - b_2 \varepsilon \right]}_{\varepsilon}$$

respectivamente  $w$

$$\rightarrow y_2 \not\perp \varepsilon; q \not\perp w$$

- Preciso de ao menos 2 instrumentos pl/ $y_2, q$ , satisfazendo as condições de ordem e porto

$$\bullet \text{Seja } \beta = \begin{bmatrix} b_0 - \frac{a_0}{a_1} \\ b_1 \\ b_2 \\ \frac{q}{a_1} \end{bmatrix}; x = \begin{bmatrix} 1 & 1 & 1 & 1 \\ z & z & y_2 & q \\ 1 & 1 & 1 & 1 \end{bmatrix}; z = \begin{bmatrix} 1 & 1 & 1 & 1 \\ 1 & z & z & z_2 \\ 1 & 1 & 1 & 1 \end{bmatrix}$$

$$\textcircled{3} \quad P_z = \hat{\beta} (\hat{x}' \hat{x})^{-1} \hat{x}'$$

$$\Rightarrow \hat{\beta}^{VI} = (\hat{x}' P_z \hat{x})^{-1} \hat{x}' P_z \hat{y}$$

ou

↳ INTERCOPÍA ESTRUTURAL NÃO-IDENTIFICADA

$$7) \text{ a) Momentos: } E(uz) = 0 = E(uz)$$

$$E(uz) = 0 \Rightarrow \hat{E}(j_z) = 0 = \frac{1}{N} \sum_{z=0}^N (y - \hat{a} - \hat{b}x) z$$

$$z \text{ binário: } 0 = \frac{1}{N} \left[ \sum_{z=0}^{z=0} (y - \hat{a} - \hat{b}x) z + \sum_{z=1}^{z=1} (y - \hat{a} - \hat{b}x) z \right]$$

Multiplicando ambos os lados por  $\frac{N}{N_i}$  ( $N_i = \# \text{ observações p/ } z = i$ )

$$\frac{1}{N_i} \sum_{z=1}^{z=1} (y - \hat{a} - \hat{b}x) z = 0 = \frac{1}{N_i} \sum_{z=1}^{z=1} \hat{z} \quad (\log \sum_{z=1}^{z=1} \hat{z} = 0)$$

$$\bar{y}^{(z=1)} - \hat{a} - \hat{b} \bar{x}^{(z=1)} = 0$$

$$\bar{E}(uz) = 0 \Rightarrow \frac{1}{N} \sum j = 0 = \frac{1}{N} \left[ \sum_{z=0}^{z=0} j + \sum_{z=1}^{z=1} j \right]$$

$$\Rightarrow \frac{1}{N} \sum_{z=0}^{z=0} j = 0$$

Multiplicando ambos os lados por  $\frac{N}{N_0}$ :  $\frac{1}{N_0} \sum_{z=0}^{z=0} j = \frac{1}{N_0} \sum_{z=0}^{z=0} (y - \hat{a} - \hat{b}x) z = 0$

$$\Rightarrow \bar{y}^{(z=0)} - \hat{a} - \hat{b} \bar{x}^{(z=0)} = 0$$

$$\Rightarrow \bar{y}^{(z=1)} - \bar{y}^{(z=0)} = b [\bar{x}^{(z=1)} - \bar{x}^{(z=0)}]$$

$$\Rightarrow \hat{b} = \frac{\bar{y}^{(z=1)} - \bar{y}^{(z=0)}}{\bar{x}^{(z=1)} - \bar{x}^{(z=0)}}$$



b) Se  $\mathbf{z}$  é binário, então  $\hat{\mathbf{x}}$  é a proporção de  $\mathbf{x}=1$ , e estima  $P_{\mathbf{x}}(\mathbf{x}=1) = \hat{\mathbf{p}}$

Em nosso caso:  $\hat{b}_{VI} = \frac{\hat{E}(Y|z=1) - \hat{E}(Y|z=0)}{P_{\mathbf{x}}(\mathbf{x}=1|z=1) - P_{\mathbf{x}}(\mathbf{x}=1|z=0)}$

O modelo fica  $Y = a + b\mathbf{x} + \varepsilon$

onde  $E(Y|\mathbf{x}=1) = a + b$

$E(Y|\mathbf{x}=0) = a$

$b = E(Y|\mathbf{x}=1) - E(Y|\mathbf{x}=0)$  é interpretado como o efeito médio de tratamento (ATE, na jargão de avaliação de impacto)

$$\begin{aligned} c) \hat{b}_VI &= \frac{\sum (x - \bar{x}^{(w)})(y - \bar{y}^{(w)})}{\sum (x - \bar{x}^{(w)})^2} = \frac{\sum_{w=w_+} (x - \bar{x}^{(w)})(y - \bar{y}^{(w)}) + \sum_{w=w_-} (x - \bar{x}^{(w)})(y - \bar{y}^{(w)})}{\sum (x - \bar{x}^{(w)})^2} \\ &= \frac{\sum_{w=w_+} (x - \bar{x}^{(w)})^2}{\sum (x - \bar{x}^{(w)})^2} \hat{b}_+ + \frac{\sum_{w=w_-} (x - \bar{x}^{(w)})^2}{\sum (x - \bar{x}^{(w)})^2} \hat{b}_- \\ &= \frac{\frac{1}{N_+} \sum_{w=w_+} (x - \bar{x}^{(w)})^2}{\frac{1}{N} \sum (x - \bar{x}^{(w)})^2} \hat{e} \hat{b}_+ + \frac{\frac{1}{N_-} \sum_{w=w_-} (x - \bar{x}^{(w)})^2}{\frac{1}{N} \sum (x - \bar{x}^{(w)})^2} (1 - \hat{e}) \hat{b}_- \\ &= \frac{V_{4R}(x|w=w_+)}{E[V_{4R}(x|w)]} \hat{e} \hat{b}_+ + \frac{V_{4R}(x|w=w_-)}{E[V_{4R}(x|w)]} (1 - \hat{e}) \hat{b}_- \end{aligned}$$

VII:  $\hat{b} = \text{cov}(x, z)$

⑥

$$8) \quad y = a + b x + \epsilon$$

$$\frac{y}{x} = b + a\left(\frac{1}{x}\right) + e$$

$$\hookrightarrow \frac{y}{x} |_{x \sim N\left(b + a\left(\frac{1}{x}\right); \sigma^2\right)}$$

$$\hat{\alpha}_{MLB} = \frac{\sum_{i=1}^n (\tilde{y}_i - \bar{\tilde{y}})(\tilde{x}_i - \bar{\tilde{x}})}{\sum_{i=1}^n (\tilde{x}_i - \bar{\tilde{x}})^2} \quad ; \text{ onde } \tilde{y}_i = \frac{y_i}{x_i}$$

$$\tilde{x}_i = \frac{1}{x_i}$$

$$\Rightarrow \hat{\alpha}_{MLB} = 1,2184$$

$$\hat{\beta} = \bar{\tilde{y}} - \hat{\alpha}_{MLB} \bar{\tilde{x}} = 1,6493$$

9) O exercício mostra que a s.tação onde

	X
Y <sub>1</sub>	1
Y <sub>2</sub>	2
Y <sub>3</sub>	3

$$\Sigma = \begin{bmatrix} 4 & 0 & 0 \\ 0 & 6 & 0 \\ 0 & 0 & 8 \end{bmatrix}$$

$$\Rightarrow \Sigma^{-1} = \begin{bmatrix} 1/4 & 0 & 0 \\ 0 & 1/6 & 0 \\ 0 & 0 & 1/8 \end{bmatrix}$$

M&G é BLUE (pois Σ é conhecido)

$$\Rightarrow \hat{\theta} = (X' \Sigma^{-1} X)^{-1} X' \Sigma^{-1} Y$$

$$= \left(\frac{49}{24}\right)^{-1} \left[ \frac{y_1}{4} + \frac{y_2}{3}, \frac{3y_3}{8} \right]$$

10)c) A loteria  $S$  neste caso foi violada como experimento aleatorizado, mas continua sendo verdade que  $\text{cov}(S, \varepsilon) = 0$   
 $\text{cov}(S, B) > 0$

Nosso modelo empírico é  $\hat{Y} = a + bS + \varepsilon$ , onde

$Y = \# \text{ calorias}$

$$\Rightarrow \hat{b} = \frac{\text{cov}(Y, S)}{\text{var}(B, S)}$$

fornecendo o resíduo do Levenshtein.

②



10) b) O problema aqui é que não sabemos, no grupo de controle, quais seriam os indivíduos que satisfaziam os critérios subjectivos do conselho do departamento. Se soubermos, podemos comparar apenas as médias dos grupos de tratamento que satisfizessem (ou não) este critério, e obter, a partir da loteria  $S$ ,

$$\text{efeito da bolsa} \leftarrow E[Y|S=1, c=1] - E[Y|S=0, c=1]$$

sobre os "quendubus"

$$\text{efeito da bolsa} \leftarrow E[Y|S=1, c=0] - E[Y|S=0, c=0]$$

sobre os "repitidos"

Se por exemplo o departamento gastar mais dos magnutinos ou dos gordutinos, temos  $B$  correlacionado com  $E$ . Assim assum,  $S$  é um bom instrumento para  $B$ .