

Lista Prática 3

Exercício 1. Neste exercício, usaremos as funções `runif()` e `rnorm()` para gerar números aleatórios com distribuições uniforme e normal, respectivamente.

- a) Gere o vetor \mathbf{x} com 10.000 números aleatórios a partir de uma distribuição uniforme no intervalo $[0, 10]$. Qual é a média e o desvio padrão de x ?
- b) Gere o vetor \mathbf{z} com 10.000 números aleatórios usando $z = 2x + \tilde{u}$, $\tilde{u} \sim N(0, 4^2)$. Qual é a correlação entre x e z ?
- c) Gere o vetor $\tilde{\varepsilon}$ (`e_til`) com 10.000 números aleatórios a partir de uma distribuição $N(0, 6^2)$. Qual é a correlação entre $\tilde{\varepsilon}$ e cada uma das demais variáveis x e z ? Além disso, verifique a correlação entre x e a soma $3z + \tilde{\varepsilon}$.
- d) Gere o vetor \mathbf{y} , considerando o seguinte modelo real:

$$y = \tilde{\beta}_0 + \tilde{\beta}_1 x + \tilde{\beta}_2 z + \tilde{\varepsilon}, \quad (1.1)$$

em que $\tilde{\beta}_0 = 10$, $\tilde{\beta}_1 = 2$ e $\tilde{\beta}_2 = 3$. Agora, estime por MQO o seguinte modelo empírico:

$$y = \beta_0 + \beta_1 x + \varepsilon. \quad (1.2)$$

A estimação conseguiu recuperar $\hat{\beta}_0 \approx \tilde{\beta}_0$ e $\hat{\beta}_1 \approx \tilde{\beta}_1$? Explique.

- e) Obtenha os resíduos de MQO, $\hat{\varepsilon}$, e verifique se valem os seguintes momentos amostrais (sujeitas a algum erro de arredondamento):

$$\frac{1}{N} \sum_{i=1}^N \hat{\varepsilon}_i = 0 \quad e \quad \frac{1}{N} \sum_{i=1}^N x_i \hat{\varepsilon}_i = 0$$

- f) O que os resultados do item (e) dizem sobre as condições de momento populacionais $E(\varepsilon) = 0$ e $E(x\varepsilon) = 0$?
- g) Denote como Caso I o modelo real visto até agora, em que $\tilde{\beta}_2 = 3$ e $z = 2x + \tilde{u}$, em que $\tilde{u} \sim N(0, 4^2)$. Gere novamente observações z e y , e estime por MQO o modelo empírico (1.2) para cada um dos seguintes modelos reais:

- Caso II: $\tilde{\beta}_2 = -3$ e $z = 2x + \tilde{u}$, $\tilde{u} \sim N(0, 4^2)$
- Caso III: $\tilde{\beta}_2 = 3$ e $z = -2x + \tilde{u}$, $\tilde{u} \sim N(0, 4^2)$
- Caso IV: $\tilde{\beta}_2 = -3$ e $z = -2x + \tilde{u}$, $\tilde{u} \sim N(0, 4^2)$

Considerando os sinais do parâmetro da variável omitida z , $\tilde{\beta}_2$, e da sua covariância com x , $cov(x, z)$, em quais casos a estimativa do parâmetro de x é sobre-estimada ($\hat{\beta}_1 > \tilde{\beta}_1$)? E em quais é sub-estimada ($\hat{\beta}_1 < \tilde{\beta}_1$)?

Resposta: A simulação é similar à realizada na subseção de Violações de hipótese.

a) $\bar{x} \approx 5$ e $dp(x) \approx 2,9$

```
1 N = 10000
2 x = runif(N, 0, 10)
3 mean(x)
4 sd(x)
```

```
1 [1] 5.048937
2 [1] 2.886117
```

b) $\bar{z} \approx 10,1$, $dp(z) \approx 7$ e $corr(x, z) \approx 0,82$

```
1 z = 2*x + rnorm(N, 0, 4)
2 mean(z)
3 sd(z)
4 cor(x, z)
```

```
1 [1] 10.12043
2 [1] 6.990625
3 [1] 0.819311
```

c) $\bar{\varepsilon} \approx 0$, $dp(\varepsilon) \approx 6$, $corr(x, \varepsilon) \approx 0$, $corr(z, \varepsilon) \approx 0$ e $corr(x, 3z + \varepsilon) \approx 0,79$

```
1 e_til = rnorm(N, 0, 6)
2 cor(x, e_til)
3 cor(z, e_til)
4 cor(x, 3*z + e_til)
```

```
1 [1] 0.04037083
2 [1] 5.95413
3 [1] 0.008887763
4 [1] 0.009301469
5 [1] 0.6326533
```

d) $\bar{y} \approx 50$ e $dp(y) \approx 26$

```
1 y = 10 + 2*x + 3*z + e_til
2 mean(y)
3 sd(y)
```

```
1 [1] 50.52809
2 [1] 26.62365
```

Agora, estimando o modelo empírico (1.2), temos

```
1 fit = lm(y ~ x)
2 fit
```

```
1 (Intercept)          x
2      10.430       7.942
```

Como $\hat{\beta}_0 \approx 10,4 \approx 10 = \tilde{\beta}_0$ e $\hat{\beta}_1 \approx 7,9 > 2 = \tilde{\beta}_1$, a estimação conseguiu recuperar apenas $\tilde{\beta}_0$ do modelo real, enquanto $\hat{\beta}_1$ é viesado (sobre-estimado) e não recuperou $\tilde{\beta}_1$.

Isto se dá pelo viés de variável omitida, pois o modelo empírico (1.2) não incluiu z como covariada, logo $\varepsilon = 3z + \tilde{\varepsilon}$. Portanto, não é válida a hipótese $E(x\varepsilon) = 0$, o que compromete as estimativas da regressão por MQO. De fato, vimos no item (b) que $\text{corr}(x, 3z + \tilde{\varepsilon}) \approx 0,79 \neq 0$.

e) $\sum_{i=1}^n \hat{\varepsilon}_i \approx 0, \quad \sum_{i=1}^n x_i \hat{\varepsilon}_i \approx 0$

```
1 sum(fit$resid)
2 sum(fit$resid * x)
```

```
1 [1] 2.039452e-12
2 [1] 5.794154e-11
```

f) O que se pode dizer é que o estimador de MQO escolhe $\hat{\beta}_0$ e $\hat{\beta}_1$ que resultem em $\sum_{i=1}^n \hat{\varepsilon}_i = 0$ e $\sum_{i=1}^n x_i \hat{\varepsilon}_i = 0$. Portanto, em qualquer regressão por MQO teremos sempre o mesmo resultado do item (e). No entanto, isto não quer dizer que as hipóteses $E(\varepsilon) = 0$ e $E(x\varepsilon) = 0$ sejam verdadeiras. Se $E(x\varepsilon) \neq 0$ (e sabemos que é, pois construímos as variáveis e deixamos z de fora), então a estimação de $\hat{\beta}_1$ será viesada.

g) II $\hat{\beta}_1 < \tilde{\beta}_1 = 2$, quando $\tilde{\beta}_2 < 0$ e $\text{cov}(x, z) > 0$

```
1 z = 2*x + rnorm(10000, 0, 4)
2 y = 10 + 2*x - 3*z + u
3 cor(x, z)
4 lm(y ~ x)
```

```
1 [1] 0.8245678
2
3 (Intercept)          x
4      10.338      -4.067
```

III $\hat{\beta}_1 < \tilde{\beta}_1 = 2$, quando $\tilde{\beta}_2 > 0$ e $\text{cov}(x, z) < 0$

```
1 z = -2*x + rnorm(10000, 0, 4)
2 y = 10 + 2*x + 3*z + e_til
3 cor(x, z)
4 lm(y ~ x)
```

```
1 [1] -0.8263252
2
3 (Intercept)          x
4      10.14      -4.04
```

IV $\hat{\beta}_1 > \tilde{\beta}_1 = 2$, quando $\tilde{\beta}_2 < 0$ e $\text{cov}(x, z) < 0$

```
1 z = -2*x + rnorm(10000, 0, 4)
2 y = 10 + 2*x - 3*z + e_til
3 cor(x, z)
4 lm(y ~ x)
```

```
1 [1] -0.819522
2
3 (Intercept)          x
4      10.166      7.997
```

Portanto, assumindo os sinais de $\tilde{\beta}_2$ e $cov(x, z)$, conseguimos ao menos analisar que, em relação ao valor verdadeiro $\tilde{\beta}_1$, a estimativa

- $\hat{\beta}_1$ é sobre-estimada ($\hat{\beta}_1 > \tilde{\beta}_1$), se $\tilde{\beta}_2 \cdot cov(x, z) > 0$, e
- $\hat{\beta}_1$ é sub-estimada ($\hat{\beta}_1 < \tilde{\beta}_1$), se $\tilde{\beta}_2 \cdot cov(x, z) < 0$.

□

Exercício 2. Neste exercício, usaremos a base de dados de Papke (1995), que possui informações sobre a participação e contribuição em planos previdência privada de empresas nos EUA, chamada de *401k*:

```
1 data(k401k, package="wooldridge")
```

- *prate*: é o percentual de trabalhadores contribuindo ativamente à previdência privada.
- *mrte*: é a taxa de “generosidade” da empresa, isto é, a razão de quanto a empresa contribui para a previdência privada de seu funcionário.
- *totemp*: é número total de funcionários.

Queremos saber a relação entre a taxa de participação de funcionários (*prate*) e a taxa de generosidade da empresa (*mrte*).

a) Estime analiticamente (sem usar a função `lm()`) o modelo:

$$prate = \beta_0 + \beta_1 mrte + \beta_2 totemp + \varepsilon$$

b) Usando operações matriciais, adapte as funções objetivo da seção de Otimização para o caso multivariado¹. Depois, usando `optim::optim()`, obtenha as estimativas que otimizam essas funções objetivo por

(i) Minimização da soma do quadrado dos resíduos

(ii) Método Generalizado dos Momentos (GMM), cujos momentos amostrais são

$$\begin{bmatrix} \sum_{i=1}^N \hat{\varepsilon}_i \\ \sum_{i=1}^N mrte_i \cdot \hat{\varepsilon}_i \\ \sum_{i=1}^N totemp_i \cdot \hat{\varepsilon}_i \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix}$$

(iii) Máxima Verossimilhança (ML)

Resposta:

a) A resolução segue da subseção de Estimação MQO multivariado:

¹Lembre-se de transformar os objetos em vetores/matrizes usando `matrix()` ou `as.matrix()` antes de fazer as operações matriciais.

```

1 y = as.matrix(k401k[, "prate"])
2 X = as.matrix(cbind(1, k401k[, c("mrate", "totemp")]))
3
4 N = nrow(k401k)
5 K = ncol(X) - 1
6
7 bhat = solve(t(X) %*% X) %*% t(X) %*% y
8 yhat = X %*% bhat
9 ehat = y - yhat
10
11 sig2hat = as.numeric( t(ehat) %*% ehat / (N-K-1) )
12 Vbhat = sig2hat * solve( t(X) %*% X )
13 se_bhat = sqrt( diag(Vbhat) )
14
15 t_bhat = bhat / se_bhat
16 p_bhat = 2 * pt(-abs(t_bhat), N-K-1)
17 cv = qt(1 - .05/2, N-K-1)
18 ci = cbind(bhat - cv*se_bhat, bhat + cv*se_bhat)
19
20 round(data.frame(bhat, se_bhat, t_bhat, p_bhat, ci), 4)

```

	bhat	se_bhat	t_bhat	p_bhat	X1	X2
1	83.4307	0.5793	144.0246	0.0000	82.2944	84.5670
2 mrate	5.8303	0.5262	11.0798	0.0000	4.7981	6.8624
3 totemp	-0.0001	0.0000	-2.5498	0.0109	-0.0002	0.0000

b) Segue da subseção de Otimização.

(i) **Minimização de função perda.** Adapta-se a função de soma dos quadrados dos resíduos com os cálculos matriciais feitos no item (a):

```

1 resid_quad = function(params, fn_args) {
2   # Extrair argumentos da lista fn_args
3   yname = fn_args[[1]]
4   Xnames = fn_args[[2]]
5   dta = fn_args[[3]]
6
7   # Extrair as variáveis da base em vetores
8   y = as.matrix(dta[, yname])
9   X = as.matrix(cbind(1, dta[, Xnames]))
10
11   bhat = matrix(params, ncol=1)
12   yhat = X %*% bhat # valores ajustados
13   ehat = y - yhat # desvios = observados - ajustados
14   sum(ehat^2)
15 }
16
17 # Otimização
18 min_loss = optimx::opm(par=c(0,0,0), fn=resid_quad,
19   fn_args=list("prate", c("mrate", "totemp"), k401k),
20   method=c("Nelder-Mead", "BFGS", "nlminb"))
21
22 round(min_loss, 4)

```

	p1	p2	p3	value	fevals	gevals	convergence
2 Nelder-Mead	83.4291	5.8347	-1e-04	394707.7	272	NA	0
3 BFGS	83.4307	5.8303	-1e-04	394707.6	52	6	0
4 nlminb	83.4307	5.8303	-1e-04	394707.6	60	64	0

- (ii) **GMM.** É o que menos se parece com o feito na seção de Otimização, pois queremos minimizar a soma ponderada dos momentos amostrais na forma matricial

$$m'Wm,$$

em que

$$m = X'\hat{\varepsilon} \quad \text{e} \quad W = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}$$

```

1 mom_ols1 = function(theta, fn_args) {
2   # No gmm(), só pode ter 1 input dos argumentos dessa função
3   # Extraindo argumentos da lista fn_args
4   yname = fn_args[[1]]
5   Xnames = fn_args[[2]]
6   dta = fn_args[[3]]
7
8   # Extraindo as variáveis da base em vetores
9   y = as.matrix(dta[,yname])
10  X = as.matrix(cbind(1, dta[,Xnames]))
11
12  bhat = matrix(theta, ncol=1)
13  yhat = X %*% bhat
14  ehat = y - yhat
15
16  ## Vetor de momentos
17  m = t(X) %*% ehat
18
19  # Ponderação
20  W = diag(length(theta)) # matriz de pesos iguais
21  as.numeric(t(m) %*% W %*% m)
22 }
23
24 # Otimização
25 gmm1 = optimx::opm(par=c(0,0,0), fn=mom_ols1,
26   fn_args=list("prate", c("mrate", "totemp"), k401k),
27   method=c("Nelder-Mead", "BFGS", "nlminb"))
28
29 round(gmm1, 4)

```

	p1	p2	p3	value	fevals	gevals	convergence
1 Nelder-Mead	0.0754	0.0792	0.0022	2.513261e+10	82	NA	0
2 BFGS	83.4307	5.8303	-0.0001	0.000000e+00	201	11	0
4 nlminb	83.4299	5.8309	-0.0001	2.592000e-01	108	95	0

- (iii) **Máxima Log-Verossimilhança.** É o mais parecido com a versão univariada, mas realizado cálculos via álgebra matricial:

```

1 loglik1 = function(theta, fn_args) {
2   # Extraindo argumentos da lista fn_args
3   yname = fn_args[[1]]
4   Xnames = fn_args[[2]]
5   dta = fn_args[[3]]
6
7   # Extraindo as variáveis da base em vetores
8   y = as.matrix(dta[,yname])
9   X = as.matrix(cbind(1, dta[,Xnames]))
10

```

```

11 bhat = matrix(theta[1:(length(theta)-1)], ncol=1)
12 sighat = theta[length(theta)]
13 yhat = X %*% bhat
14 log_ypdf = dnorm(y, mean = yhat, sd = sighat, log = TRUE)
15
16 ## Calculando a log-verossimilhança
17 loglik = sum(log_ypdf)
18
19 ## Retornando o negativo da log-verossimilhança
20 -loglik # Negativo, pois mle2() minimiza e queremos maximizar
21 }
22
23 mle1 = optimx::opm(par=c(0,0,0,100), fn=loglik1,
24   fn_args=list("prate", c("mrate", "totemp"), k401k),
25   method=c("Nelder-Mead", "BFGS", "nlminb"))
26 round(mle1, 4)

```

		p1	p2	p3	p4	value	fevals	gevals	convergence
2	Nelder-Mead	83.4318	5.8306	-1e-04	16.0414	6433.706	267	NA	0
3	BFGS	83.4308	5.8302	-1e-04	16.0408	6433.706	95	25	0
4	nlminb	83.4307	5.8303	-1e-04	16.0408	6433.706	37	107	0

□

Exercício 3. Neste exercício, usaremos a base de dados *wage1* do pacote *wooldridge* e pode ser carregada no R usando o comando:

```
1 data(wage1, package="wooldridge")
```

Queremos saber a relação entre anos de estudo (*educ*) e o logaritmo da renda das pessoas (*lwage*), considerando seus sexos/gêneros.

- a) Gere duas bases a partir de *wage1*: uma apenas com mulheres (*wage_female*) e outra apenas com homens (*wage_male*), e estime os seguintes modelos (sem interceptos):

$$\begin{aligned} \text{coninc} &= \beta_F \cdot \text{educ} + \varepsilon && \text{(base com mulheres)} \\ \text{coninc} &= \beta_M \cdot \text{educ} + \varepsilon && \text{(base com homens)} \end{aligned}$$

Quais são as estimativas para β_F e β_M ?

- b) Usando a base completa (*wage1*), plote um gráfico de dispersão (*scatterplot*) entre anos de estudo \times renda, colorindo os pontos de acordo com o sexo da pessoa. Também, adicione as retas das regressões feitas no item (a) com cores distintas.
- c) Na base completa (*wage1*), regrida um único modelo em que, com as estimativas obtidas, possamos calcular $\hat{\beta}_F$ e $\hat{\beta}_M$ encontrados no item (a). A diferença entre $\hat{\beta}_F$ e $\hat{\beta}_M$ é estatisticamente significativa?

Resposta:

- a) $\hat{\beta}_F = 0.1135$ e $\hat{\beta}_M = 0.1385$. Faremos as regressões sem intercepto para ambas amostras:

```

1 # Gerando 2 bases com trab. em tempo integral de mulheres e de homens
2 wage_male = wage1[wage1$female==0,]
3 wage_female = wage1[wage1$female==1,]
4
5 # Estimando os modelos sem constante
6 reg_male = lm(lwage ~ 0 + educ, wage_male)
7 reg_female = lm(lwage ~ 0 + educ, wage_female)
8
9 # Mostrando os betas estimados
10 reg_male$coef
11 reg_female$coef

1 0.1384512
2 0.1135278

```

b)

```

1 # Plotando anos de educação X renda
2 plot(wage1$educ, wage1$lwage, col=wage1$female+1,
3      main="log(Income) by Years of Study")
4 # Plotando as retas das regressões estimadas
5 abline(reg_female, col="red")
6 abline(reg_male, col="black")
7 legend("topleft", pch=1, col=c("black", "red"),
8      legend=c("Male", "Female"))

```



c) Vamos estimar o modelo que, além da covariada de anos de estudo, vamos incluir a interação entre anos de estudo *educ* e a *dummy* *female*:

$$\text{coninc} = \beta_1.\text{educ} + \beta_2.\text{educ}.\text{female} + \varepsilon$$

```

1 # Estimando o modelo com interação entre anos de educ. e dummy mulher
2 reg_full = lm(lwage ~ 0 + educ + educ:female, wage1)
3 summary(reg_full)

```



```

1           Estimate Std. Error t value Pr(>|t|)
2 educ       0.138451   0.002161  64.077 < 2e-16 ***
3 educ:female -0.024923   0.003197  -7.797 3.45e-14 ***
4 ---
5 Signif. codes:  0   ***    0.001   **    0.01   *    0.05   .    0.1

```

Note que $\hat{\beta}_M = \hat{\beta}_1$ e $\hat{\beta}_F = \hat{\beta}_1 + \hat{\beta}_2$. Além disso, a diferença entre as estimativas, $\hat{\beta}_2 = \hat{\beta}_F - \hat{\beta}_M$, é estatisticamente significativa a 0,1%.

□

Exercício 4. *Analizando apenas trabalhadores em tempo integral e parcial (“Working Fulltime” e “Working Parttime”), verifique a possível discriminação na renda em relação aos povos hispânicos (mexicanos, porto riquenhos, cubanos, etc.). Para isto use a base de dados General Social Survey (GSS)², que pode ser carregada no R usando o comando:*

```
1 load(url("https://fhnishida.netlify.app/project/rec5004/gss.Rdata"))
```

- a) Regrida a renda (`coninc`) em relação às dummies dos povos hispânicos e liste os que possuem diferença significativa de renda em relação aos não-hispânicos. Utilize como variáveis de controle: o sexo, a idade, a idade², a raça/cor de pele, os anos de estudo (`educ`) e o status de trabalho (`wrkstat`).
- b) Note que a regressão anterior “jogou fora” quase 70% das observações por causa de valores ausentes (NA’s) das variáveis utilizadas, sobretudo de `hispanic`. Caso essas informações estejam faltando aleatoriamente (missing at random), pode ser razoável considerar o resultado do item (a) como representativo de toda população trabalhadora nos EUA. Para verificar isso, siga os passos abaixo:
 - i. Para facilitar, selecione apenas as colunas/variáveis usadas na regressão do item (a)
 - ii. Crie uma variável dummy `missing` que é igual a 1 se houver pelo menos um NA na linha/observação, e igual a 0 caso contrário.
 - iii. Crie variáveis dummies para as variáveis categóricas `sex` e `race`.
 - iv. Usando regressões de diferença de médias, verifique a significância das diferenças entre as observações retiradas da regressão do item (a) (`missing==1 / NA`), e as que foram mantidas (`missing==0 / nonNA`)
 - v. Crie e analise a seguinte tabela com os resultados:

	nonNA	NA	diferença	p-valor
<code>coninc</code>	-	-	-	-
<code>sex_female</code>	-	-	-	-
<code>age</code>	-	-	-	-
<code>race_white</code>	-	-	-	-
<code>race_black</code>	-	-	-	-
<code>educ</code>	-	-	-	-

²Disponibilizado por Bryan Wheeler (2014)

Resposta:

a) Mexicanos a 0,1%, Filipinos a 5%, Argentinos e Porto Riquenhos a 10%:

```

1 # Filtrando base com trabalhadores fulltime e parttime
2 gss = gss[gss$wrkstat %in% c("Working Fulltime", "Working Parttime"),]
3
4 # definindo Not Hispanic como referencia
5 gss$hispanic = relevel(gss$hispanic, ref="Not Hispanic")
6
7 # regressão
8 reg = lm(coninc ~ hispanic + sex + age + I(age^2) +
9         race + educ + wrkstat, gss)
10 summary(reg)
```


	Estimate	Std. Error	t value	Pr(> t)	
(Intercept)	-76942.435	4104.084	-18.748	< 2e-16 ***	
hispanicMexican, Mexican American	-6158.952	1711.843	-3.598	0.000322 ***	
hispanicPuerto Rican	-5831.574	3195.995	-1.825	0.068082 .	
hispanicCuban	-727.544	5755.621	-0.126	0.899413	
hispanicSalvadorian	-6341.522	6006.062	-1.056	0.291060	
hispanicGuatemalan	-1289.261	7959.050	-0.162	0.871319	
hispanicPanamanian	-18409.278	12850.695	-1.433	0.152016	
hispanicNicaraguan	-13707.093	13653.226	-1.004	0.315428	
hispanicCosta Rican	15386.564	22241.821	0.692	0.489088	
hispanicCentral American	-6364.602	11644.985	-0.547	0.584698	
hispanicHonduran	-3260.999	9975.247	-0.327	0.743743	
hispanicDominican	-11471.848	8454.734	-1.357	0.174857	
hispanicWest Indian	3739.035	38519.432	0.097	0.922674	
hispanicPeruvian	-6149.380	10701.734	-0.575	0.565564	
hispanicEquadorean	-10500.778	10714.220	-0.980	0.327070	
hispanicColumbian	-5315.638	10301.585	-0.516	0.605864	
hispanicVenezuelan	4602.093	13621.146	0.338	0.735473	
hispanicArgentinian	47851.664	27233.777	1.757	0.078935 .	
hispanicSpanish	-7198.788	5416.767	-1.329	0.183883	
hispanicBasque	-14484.157	38494.135	-0.376	0.706724	
hispanicFilipino/A	41203.692	19262.145	2.139	0.032451 *	
hispanicLatin American	-12548.006	22230.069	-0.564	0.572453	
hispanicSouth American	-5027.299	12859.208	-0.391	0.695843	
hispanicLatino/A	-14379.493	15748.125	-0.913	0.361215	
hispanicHispanic	-18581.959	22247.698	-0.835	0.403607	
hispanicOther, Not Specified	-19508.177	14556.634	-1.340	0.180223	
sexFemale	-8196.156	766.173	-10.698	< 2e-16 ***	
age	2946.157	176.359	16.705	< 2e-16 ***	
I(age^2)	-27.439	1.988	-13.804	< 2e-16 ***	
raceBlack	-14506.432	1119.148	-12.962	< 2e-16 ***	
raceOther	2511.628	1474.706	1.703	0.088572 .	
educ	5041.284	135.727	37.143	< 2e-16 ***	
wrkstatWorking Parttime	-6199.141	1047.625	-5.917	3.38e-09 ***	

Signif. codes:	0	***	0.001 **	0.01 *	0.05 . 0.1

Residual standard error: 38490 on 10422 degrees of freedom
(23594 observations deleted due to missingness) <<<<<<<<<<<<<<<<<<<<<<
Multiple R-squared: 0.2148, Adjusted R-squared: 0.2124
F-statistic: 89.09 on 32 and 10422 DF, p-value: < 2.2e-16

b) Note que 23.594 das 34.049 observações (69,3%) foram excluídas da regressão por causa

de missing values (NA's). Então, vamos comparar as diferenças das médias de algumas variáveis para as duas amostras:

```
1 library(dplyr)
2 gss = gss %>% select(coninc, hispanic, sex, age, race, educ, wrkstat) %>%
3   mutate(
4     missing = ifelse(is.na(coninc) | is.na(hispanic) | is.na(sex) | is.na(age)
5       | is.na(race) | is.na(educ) | is.na(wrkstat), 1, 0)
6   )
7
8 gss %>% is.na() %>% apply(2, sum) # NA's por variável
9 sum(gss$missing) # qtd de observ. com NA's
10 sum(gss$missing) / nrow(gss) # % NA's
```

```
1   coninc hispanic      sex      age      race      educ  wrkstat  missing
2     2600    22434        0     109        0        75        0        0
3 [1] 23594
4 [1] 0.6929425
```

Como pode ser visto acima, grande parte dos NA's ocorreram na variável `hispanic`. Em `gss`, criaremos a variável binária `missing`, que indica se a observação possui algum missing value nas variáveis utilizadas na regressão. Também, incluiremos dummies das variáveis `sex`, `race`.

```
1 # criando variáveis dummies
2 gss = fastDummies::dummy_cols(gss, c("sex", "race"))
3 names(gss)
```

```
1 [1] "coninc"      "hispanic"    "sex"         "age"         "race"
2 [6] "educ"       "wrkstat"     "missing"     "sex_Male"    "sex_Female"
3 [11] "race_White" "race_Black"  "race_Other"
```

Agora, calcularemos as diferenças de média das variáveis de renda, sexo, idade, raça e anos de educação. Abaixo, vamos criar uma vetor com os nomes das variáveis (`vars`) para usar um loop - assim não precisamos escrever uma regressão para cada variável. As funções `eval(parse(text="..."))` são utilizadas para transformar um nome/texto em um objeto/variável com este nome. Vamos guardar as estimativas e p-valores de cada variável na matriz `resultados`.

```
1 # diferenças de médias
2 vars = c("coninc", "sex_Female", "age", "race_White", "race_Black", "educ")
3
4 resultados = matrix(0, length(vars), 4) %>% .data.frame()
5 colnames(resultados) = c("nonNA", "NA", "dif", "p-valor")
6 rownames(resultados) = vars
7
8 # loop para fazer regressão e preencher tabela
9 for (var in vars) {
10   reg = lm(eval(parse(text=var)) ~ missing, gss) %>% summary() %>% coef()
11   resultados[var, 1] = reg["(Intercept)", "Estimate"]
12   resultados[var, 2] = reg["(Intercept)", "Estimate"] + reg["missing", "
13     Estimate"]
14   resultados[var, 3] = reg["missing", "Estimate"]
15   resultados[var, 4] = reg["missing", "Pr(>|t|)"]
16 }
17 resultados %>% round(3)
```

	nonNA	NA	dif	p-valor
1 coninc	56103.154	48686.478	-7416.676	0.000
2 sex_Female	0.494	0.475	-0.019	0.002
3 age	41.707	39.877	-1.830	0.000
4 race_White	0.765	0.834	0.070	0.000
5 race_Black	0.137	0.130	-0.007	0.066
6 educ	13.881	13.210	-0.671	0.000

Note que apenas a proporção de negros não é estatisticamente diferente a 5% de significância. Logo, os missing values não parecem ter ocorrido de forma aleatória, pois as diferenças são estatisticamente significantes.

□

Exercício 5. *O seguinte modelo pode ser usado para estudar se gastos na campanha afetam os resultados eleitorais:*

$$voteA = \beta_0 + \beta_1 \log(expendA) + \beta_2 \log(expendB) + \beta_3 prtystA + \varepsilon$$

em que:

- *voteA* é o percentual de votos recebidos pelo Candidato A
 - *expendA* e *expendB* são gastos de campanha pelos Candidatos A e B, respectivamente
 - *prtystA* é uma medida de força do partido do Candidato A
- a) Declare a hipótese nula: o impacto nos votos do Candidato A por um aumento em 1% nos seus gastos é anulado por um aumento em 1% de gastos de B.
- b) Usando a base de dados *vote1* do pacote *wooldridge*, estime o modelo acima.
- c) Faça o teste hipótese do item (a). Dica: Você pode obter as variâncias e covariâncias das estimativas usando *vcov()* no objeto de regressão gerado por *lm()*.

Resposta:

a) $H_0: \beta_1 + \beta_2 = 0$

b) Usando *lm()*:

```
1 reg = lm(voteA ~ log(expendA) + log(expendB) + prtystA, data=vote1)
2 round(summary(reg)$coef, 4)
```

	Estimate	Std. Error	t value	Pr(> t)
1 (Intercept)	45.0789	3.9263	11.4813	0.0000
2 log(expendA)	6.0833	0.3821	15.9187	0.0000
3 log(expendB)	-6.6154	0.3788	-17.4632	0.0000
4 prtystA	0.1520	0.0620	2.4502	0.0153

c) (1) É possível fazer o teste de hipótese “na mão” usando

$$t = \frac{\hat{\beta}_1 + \hat{\beta}_2}{\sqrt{\text{var}(\hat{\beta}_1) + \text{var}(\hat{\beta}_2) + \text{cov}(\hat{\beta}_1, \hat{\beta}_2)}} = \frac{-0,532}{\sqrt{0,146 + 0,144 + 2(-0,003)}} = \frac{-0,532}{0,533} \approx 1$$

Podemos encontrar as variâncias e covariâncias das estimativas por meio da função `vcov()`:

```
1 vcov(reg) # matriz de variâncias-covariâncias do estimador

1              (Intercept) log(expendA) log(expendB) prtystA
2 (Intercept)      15.4159      -0.3949      -0.8741     -0.1762
3 log(expendA)      -0.3949       0.1460      -0.0027     -0.0065
4 log(expendB)      -0.8741      -0.0027       0.1435      0.0036
5 prtystA           -0.1762      -0.0065       0.0036      0.0038

1 var_b1 = vcov(reg)[2,2]
2 var_b2 = vcov(reg)[3,3]
3 cov_b1b2 = vcov(reg)[2,3]
4 sqrt( var_b1 + var_b2 + 2*(cov_b1b2) )

1 [1] 0.5330858
```

(2) Também é possível fazer o teste por meio de uma regressão. Defina $\theta = \beta_1 + \beta_2 \iff \beta_1 = \theta - \beta_2$, substitua β_1 no modelo, e isole θ :

$$\begin{aligned} \text{voteA} &= \beta_0 + \beta_1 \log(\text{expendA}) + \beta_2 \log(\text{expendB}) + \beta_3 \text{prtystA} + \varepsilon \\ &= \beta_0 + (\theta - \beta_2) \log(\text{expendA}) + \beta_2 \log(\text{expendB}) + \beta_3 \text{prtystA} + \varepsilon \\ &= \beta_0 + \theta \log(\text{expendA}) + \beta_2 [\log(\text{expendB}) - \log(\text{expendA})] + \beta_3 \text{prtystA} + \varepsilon \end{aligned}$$

```
1 reg2 = lm(voteA ~ log(expendA) + I(log(expendB)-log(expendA)) + prtystA,
2         data=vote1)
3 round(summary(reg2)$coef, 4)

1              Estimate Std. Error t value Pr(>|t|)
2 (Intercept)      45.0789      3.9263  11.4813  0.0000
3 log(expendA)      -0.5321      0.5331  -0.9982  0.3196
4 I(log(expendB) - log(expendA)) -6.6154      0.3788 -17.4632  0.0000
5 prtystA           0.1520      0.0620   2.4502  0.0153
```

Agora, basta verificar a estatística t (ou p-valor) de $\hat{\theta}$.

□

Exercício 6. Use a base de dados sobre salários na liga americana de beisebol `mlb1`, do pacote `wooldridge`, para este exercício e considere o modelo:

$$\log(\text{salary}) = \beta_0 + \beta_1 \text{years} + \beta_2 \text{gamesyr} + \beta_3 \text{bavg} + \beta_4 \text{hrunsyr} + \varepsilon$$

em que:

- *salary* é o salário do jogador
- *years* é a quantidade de anos como jogador profissional
- *gamesyr* é a média de jogos por ano do jogador
- *bavg* é o percentual de rebatida
- *hrunsyr* é a média de home runs por ano

- a) Adicione *runsyr* (corridas por ano), *fldperc* (percentual de defesa), e *sbasesyr* (bases roubadas por ano) ao modelo. Quais destes fatores são individualmente significantes?
- b) A partir do modelo do item (a), teste a significância conjunta de *bavg*, *fldperc*, e *sbasesyr*. Faça “na mão” os dois testes possíveis para este caso e analise-os.

Resposta:

- a) Apenas *runsyr* é estatisticamente significativa.

```
1 reg3 = lm(log(salary) ~ years + gamesyr + bavg + hrunsyr + runsyr
2         + fldperc + sbasesyr, mlb1)
3 round(summary(reg3)$coef, 4)
```

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	10.4083	2.0033	5.1957	0.0000
years	0.0700	0.0120	5.8440	0.0000
gamesyr	0.0079	0.0027	2.9504	0.0034
bavg	0.0005	0.0011	0.4798	0.6317
hrunsyr	0.0232	0.0086	2.6867	0.0076
runsyr	0.0174	0.0051	3.4344	0.0007
fldperc	0.0010	0.0020	0.5164	0.6059
sbasesyr	-0.0064	0.0052	-1.2382	0.2165

- b) (1) Primeiro, vamos testar as $G = 3$ restrições conjuntamente ($\beta_3 = \beta_6 = \beta_7 = 0$) por meio do teste de Wald:

$$w(\hat{\beta}) = \left[R\hat{\beta} - h \right]' \left[RV_{\hat{\beta}}R' \right]^{-1} \left[R\hat{\beta} - h \right] \sim \chi^2_{(G)}$$

```
1 bhat = matrix(reg3$coef, ncol=1)
2 Vbhat = vcov(reg3)
3 G = 3 # Número de restrições
4 # Matriz das restrições
5 R = matrix(c(0, 0, 0, 1, 0, 0, 0, 0,
6             0, 0, 0, 0, 0, 0, 1, 0,
7             0, 0, 0, 0, 0, 0, 0, 1),
8           nrow=G, byrow=TRUE)
9 # Vetor de constantes h (b3 = b6 = b7 = 0)
10 h = matrix(c(0, 0, 0),
11           nrow=3, ncol=1)
12 # Estatística de Wald
13 w = t( R %*% bhat - h ) %*% solve( R %*% Vbhat %*% t(R) ) %*% (R %*% bhat - h)
14 1 - pchisq(w, df=G) # p-valor
```

```
1 [1,] 0.5610675
```

(2) Agora, verificaremos pelo teste F

$$F = \frac{R_{ur}^2 - R_r^2}{1 - R_{ur}^2} \cdot \frac{N - K - 1}{G}$$

```
1 N = nrow(mlb1)
2 K = length(reg3$coef) - 1
3 reg3r = lm(log(salary) ~ years + gamesyr + hrunsyr + runsyr, mlb1)
4 r2ur = summary(reg3)$r.squared
5 r2r = summary(reg3r)$r.squared
6 F = ( r2ur - r2r ) / (1 - r2ur) * (N-K-1) / G
7 1 - pf(F, G, N-K-1) # p-valor
```

```
1 [1] 0.5617088
```

Portanto, não rejeitamos a hipótese nula de que $\beta_3 = \beta_6 = \beta_7 = 0$

□